

# Dimensionality Reduction

Alessandro Minoli  
Flavio Perini  
Francesco Torgano

SciViz A.A. 2020-21













UNIVERSITÀ  
DEGLI STUDI  
DI MILANO

# ISOMAP


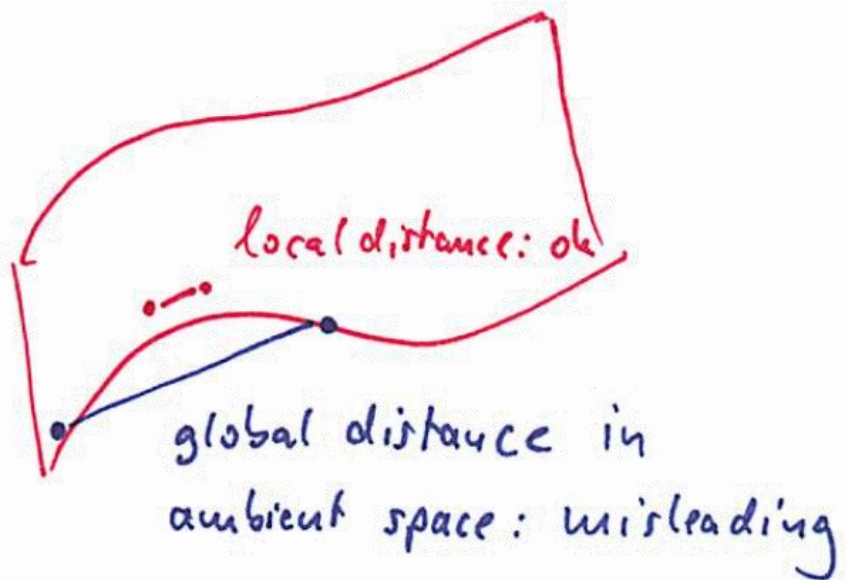


# Cosa significa ridurre la dimensionalità?






# L'intuizione



# Algoritmo di ISOMAP



Input:

- $X$  (ad alta dimensionalità)
- una funzione di **distanza**  $d(x_i, x_j)$ , scegliamo la euclidea

## 1) Costruzione del grafo pesato

**Troviamo i neighbors  $\mathcal{N}_i$  di ogni punto  $x_i$**


K-nearest neighbors  $\Rightarrow |\mathcal{N}_i| = k$

Fixed radius  $\Rightarrow \mathcal{N}_i = \{j \mid \|x_j - x_i\| \leq r\}$


**Uniamo i neighbors  $\mathcal{N}_i$  a  $x_i$  con archi di peso**

$$w_{ij} = \|x_j - x_i\|, \forall j \in \mathcal{N}_i \quad (\text{distanze } \mathbf{locali})$$





- grafo **connesso**
- vale la **disuguaglianza triangolare**




## 2) Ricava la matrice di distanze $D$

calcolando le distanze  $d_{sp}$  dei cammini minimi fra tutte le coppie di punti usando l'algoritmo di Dijkstra o di Floyd-Warshall

(distanze **geodesiche**)

# Come scegliere $k$





### 3) Applica metric MDS con $D$ come input per ottenere $X$ (a bassa dimensionalità), cioè un embedding del dataset che preserva le distanze geodesiche

Data  $D \in \mathbb{R}^{n \times n}$ ,  $d_{ij} = \|x_i - x_j\|$  ricava i punti  $(x_i)_{i=1 \dots n} \in \mathbb{R}^d$

Questo problema di embedding è chiamato **(metric) multi-dimensional scaling**

Più generalmente il problema è:

Dati gli oggetti  $x_1, \dots, x_n \in X$  (ad alta dimensionalità),  
trova un embedding  $\Phi : X \rightarrow \mathbb{R}^d$  t.c.  $\|\Phi(x_i) - \Phi(x_j)\| = d_{ij}$

Per una generale  $D$ , **non possiamo** ottenere un tale embedding **senza distorsione** dei dati



# Classic MDS

Data una  $D$  di **distanze euclidee** possiamo esprimere in termini di entrate di  $D$  la **matrice di Gram**  $S$  con entrate  $s_{ij} = (\langle x_i, x_j \rangle)_{ij=1\dots n}$  in questo modo:

$$d_{ij}^2 = \|x_i - x_j\|^2 = \langle x_i - x_j, x_i - x_j \rangle = \langle x_i, x_i \rangle + \langle x_j, x_j \rangle - 2\langle x_i, x_j \rangle$$

$$s_{ij} = \langle x_i, x_j \rangle = \frac{1}{2} (\langle x_i, x_i \rangle + \langle x_j, x_j \rangle - d_{ij}^2) = \frac{1}{2} (d(0, x_i)^2 + d(0, x_j)^2 - d_{ij}^2) = \frac{1}{2} (d_{1i}^2 + d_{1j}^2 - d_{ij}^2)$$

$S$  è una matrice definita positiva, perciò possiamo decomporla nella forma  $S = XX^t$ ,  $X \in \mathbb{R}^{n \times d}$

**L'  $i$ -esima riga di  $X$  sarà l'embedding del punto  $x_i$  in  $\mathbb{R}^d$**

Per trovare  $X$  calcoliamo la decomposizione spettrale di  $S = V\Lambda V^t$  e poniamo  $X = V\sqrt{\Lambda}$ .


Tipicamente, scegliamo una dimensione  $d \leq n$  e poniamo:

- $V_d$  uguale alle prime  $d$  colonne di  $V$
- $\Lambda_d$  uguale alla matrice diagonale  $d \times d$  con i primi  $d$  autovalori sulla diagonale
- $X = V_d\sqrt{\Lambda_d}$



# Un esempio numerico

(ci sto lavorando ma escono risultati non belli ☹)



$k = 2$

	x1	x2	x3	x4	x5	x6	x7
x1	0	1	1.2	1.9	1.5	1.5	1.8
x2	1	0	1.7	0.9	1.5	2.0	2.2
x3	1.2	1.7	0	0.8	0.3	0.3	0.6
x4	1.9	0.9	0.8	0	0.6	1.1	1.3
x5	1.5	1.5	0.3	0.6	0	0.5	0.7
x6	1.5	2.0	0.3	1.1	0.5	0	0.3
x7	1.8	2.2	0.6	1.3	0.7	0.3	0

# Metric MDS

Se  $D$  non è di sole distanze euclidee non riusciremo a ricavare un embedding perfetto.


Perciò definiamo una funzione di **stress**, ad esempio:

$$stress(embedding) = \frac{\sum_{ij} (\|x_i - x_j\| - d_{ij})^2}{\sum_{ij} \|x_i - x_j\|}$$


Cercheremo di trovare un embedding  $x_1, \dots, x_n$  che minimizzi lo stress tramite un algoritmo standard di ottimizzazione non convessa (es. discesa del gradiente).




- Garanzia teorica che, con  $x_1, \dots, x_n$  campioni presi uniformemente da un manifold "buono", per  $n \rightarrow \infty$  e  $k \approx \log n$  i cammini minimi sul grafo pesato convergono alle distanze geodesiche fra i campioni
- $O[D \log(k) N \log(N)] + O[N^2(k + \log(N))] + O[dN^2]$
- Problema dei buchi nel manifold



ISOMAP (global)



LLE (local)





# ISOMAP sul dataset di cifre MNIST

