

Dimensionality Reduction

Alessandro Minoli
Flavio Perini
Francesco Torgano

SciViz A.A. 2020-21

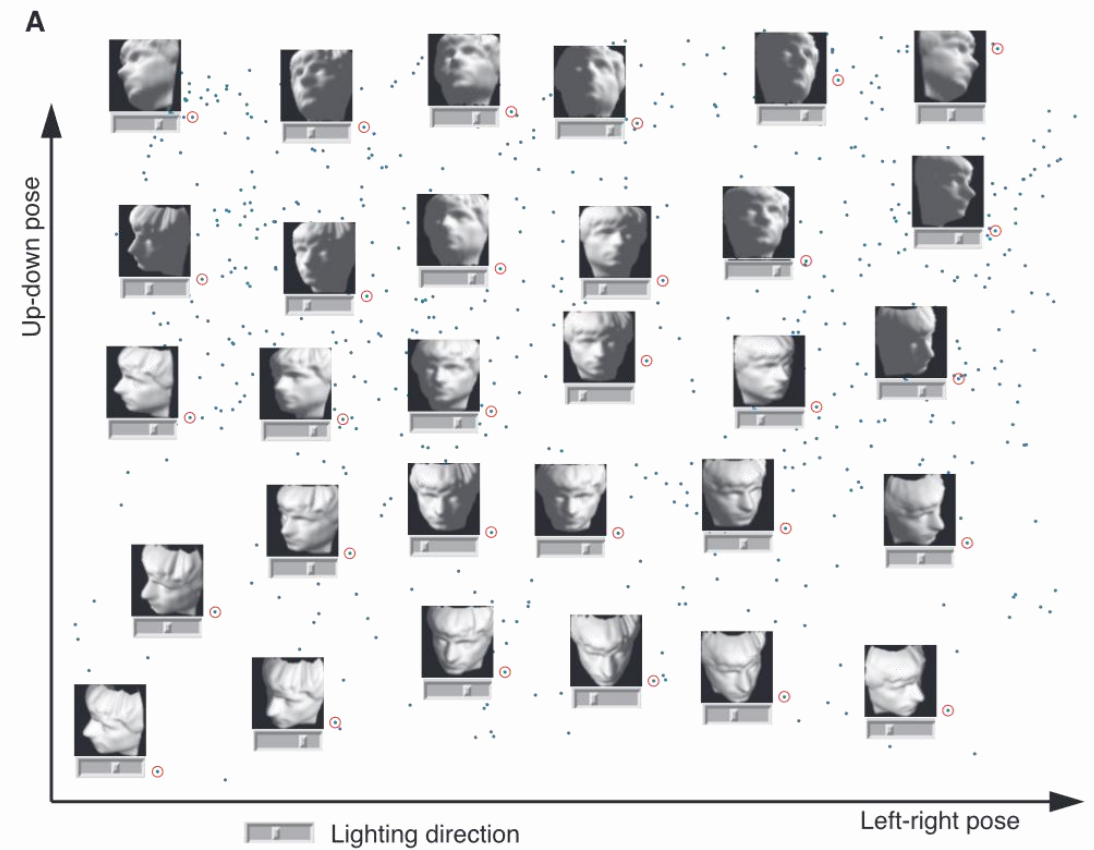












UNIVERSITÀ
DEGLI STUDI
DI MILANO

ISOMAP


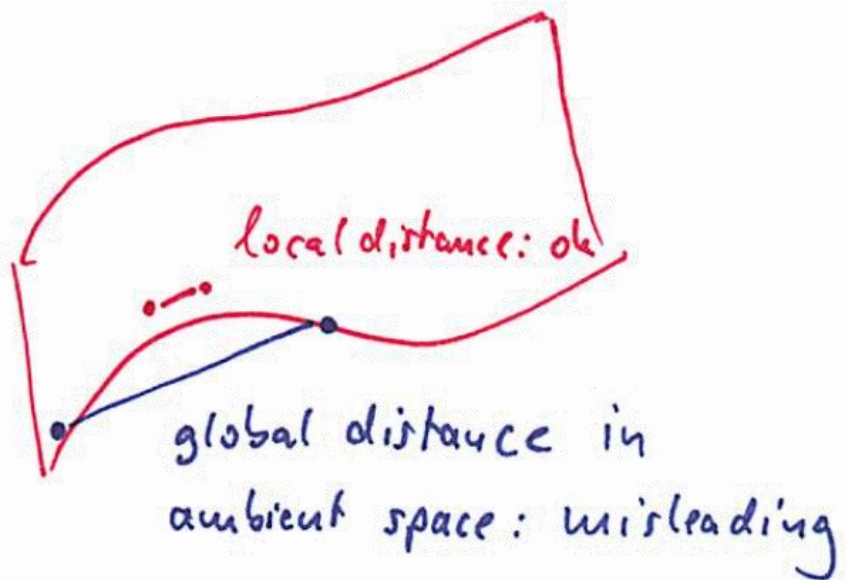


Cosa significa ridurre la dimensionalità?






L'intuizione



Algoritmo di ISOMAP



Input:

- X (ad alta dimensionalità)
- una funzione di **distanza** $d(x_i, x_j)$, scegliamo la euclidea

1) Costruzione del grafo pesato

Troviamo i neighbors \mathcal{N}_i di ogni punto x_i


K-nearest neighbors $\Rightarrow |\mathcal{N}_i| = k$

Fixed radius $\Rightarrow \mathcal{N}_i = \{j \mid \|x_j - x_i\| \leq r\}$


Uniamo i neighbors \mathcal{N}_i a x_i con archi di peso

$$w_{ij} = \|x_j - x_i\|, \forall j \in \mathcal{N}_i \quad (\text{distanze } \mathbf{locali})$$





- grafo **connesso**
- vale la **disuguaglianza triangolare**




2) Ricava la matrice di distanze D


calcolando le distanze d_{sp} dei cammini minimi fra tutte le coppie di punti usando l'algoritmo di Dijkstra o di Floyd-Warshall

(distanze **geodesiche**)

Come scegliere k



Matrice di distanze D



	x1	x2	x3	x4	x5	x6	x7
x1	0	1	1.2	1.9	1.5	1.5	1.8
x2	1	0	1.7	0.9	1.5	2.0	2.2
x3	1.2	1.7	0	0.8	0.3	0.3	0.6
x4	1.9	0.9	0.8	0	0.6	1.1	1.3
x5	1.5	1.5	0.3	0.6	0	0.5	0.7
x6	1.5	2.0	0.3	1.1	0.5	0	0.3
x7	1.8	2.2	0.6	1.3	0.7	0.3	0

3) Applica metric MDS con D come input per ottenere X (a bassa dimensionalità), cioè un embedding del dataset che preserva le distanze geodesiche

Data $D \in \mathbb{R}^{n \times n}$, $d_{ij} = \|x_i - x_j\|$, ricava i punti $(x_i)_{i=1 \dots n} \in \mathbb{R}^d$

Questo problema di embedding è chiamato **(metric) multi-dimensional scaling**

Più generalmente il problema è:

Dati gli oggetti $x_1, \dots, x_n \in X$ (ad alta dimensionalità),
trova un embedding $\Phi : X \rightarrow \mathbb{R}^d$ t.c. $\|\Phi(x_i) - \Phi(x_j)\| = d_{ij}$

Per una generale D , **non possiamo** ottenere un tale embedding **senza distorsione** dei dati



Classic MDS

Data una D di **distanze euclidee** possiamo esprimere in termini di entrate di D la **matrice di Gram** S con entrate $s_{ij} = (\langle x_i, x_j \rangle)_{ij=1\dots n}$ in questo modo:

$$s_{ij} = \langle x_i, x_j \rangle = \dots = \frac{1}{2} (d_{1i}^2 + d_{1j}^2 - d_{ij}^2)$$

S è una matrice definita positiva, perciò possiamo decomporla nella forma $S = XX^t$, $X \in \mathbb{R}^{n \times d}$

L' i -esima riga di X sarà l'embedding del punto x_i in \mathbb{R}^d

Per trovare X calcoliamo la decomposizione spettrale di $S = V\Lambda V^t$

Tipicamente, scegliamo una dimensione $d \leq n$ e poniamo:

- V_d uguale alle prime d colonne di V
- Λ_d uguale alla matrice diagonale $d \times d$ con i primi d autovalori sulla diagonale
- $X = V_d \sqrt{\Lambda_d}$



Metric MDS

Se D non è di sole distanze euclidee non riusciremo a ricavare un embedding perfetto.


Perciò definiamo una funzione di **stress**, ad esempio:

$$\text{stress}(\text{embedding}) = \sqrt{\sum_{i=1}^n \sum_{j=1|i \neq j}^n (\|x_i - x_j\| - d_{ij})^2}$$


Cercheremo di trovare un embedding x_1, \dots, x_n che minimizzi lo stress tramite un algoritmo standard di ottimizzazione non convessa (es. discesa del gradiente).




- Garanzia teorica che, con x_1, \dots, x_n campioni presi uniformemente da un manifold "buono", per $n \rightarrow \infty$ e $k \approx \log n$ i cammini minimi sul grafo pesato convergono alle distanze geodesiche fra i campioni
- $O[D \log(k) N \log(N)] + O[N^2(k + \log(N))] + O[dN^2]$
- Problema dei buchi nel manifold




ISOMAP (global)



LLE (local)



IsoMap projection of MNIST digits dataset (size: 1797, time: 2.96s)



IsoMap projection of Fashion-MNIST dataset (size: 5000, time: 21.29s)

